Agrupación de la calidad del agua potable en Colombia

Cómo se agrupan los municipios según su riesgo

Curso: Aprendizaje No Supervisado (Clustering)

Actividad: Informe final de proyecto de agrupamiento

Autor:

Cristian Alejandro Perdomo Rivas

Universidad de Cundinamarca

7 de noviembre de 2026

Resumen

El Índice de Riesgo de la Calidad del Agua para Consumo Humano (IRCA) es la medida oficial que usa Colombia para saber qué tan segura es el agua potable de cada municipio. Va de 0 a 100: cuanto mayor es el valor, mayor es el riesgo para la salud. Este trabajo tomó los datos de 19.610 observaciones municipio-año entre 2007 y 2025, publicados por el Instituto Nacional de Salud (INS) en el portal de Datos Abiertos de Colombia, y los agrupó con tres técnicas de aprendizaje automático (K-Means, DBSCAN y agrupación jerárquica) para descubrir patrones que no se ven a simple vista.

El objetivo era saber si los municipios se pueden clasificar de forma automática y útil según su nivel de riesgo. El resultado más claro es que los datos sí permiten separar a los municipios en dos o tres grandes grupos de riesgo (bajo, medio y alto). Además, se observó que el riesgo tiende a ser mayor en las zonas rurales que en las urbanas, y que los municipios con agua más riesgosa se concentran en zonas específicas del país. Estos hallazgos pueden ayudar a las autoridades a decidir dónde invertir con prioridad en agua potable.

Palabras clave: IRCA, calidad del agua, agrupación de datos, K-Means, DBSCAN, agrupación jerárquica.

1. Datos

1.1. De dónde vienen los datos

Los datos provienen del **Portal Nacional de Datos Abiertos de Colombia** (`datos.gov.co`), que administra el Ministerio de Tecnologías de la Información y las Comunicaciones. El conjunto usado se llama *"Calidad del Agua para Consumo Humano en Colombia"* y lo publica el **Instituto Nacional de Salud** (INS, 2025) a través del sistema SIVICAP, encargado de vigilar la calidad del agua potable en todo el país.

1.2. Qué es el IRCA

El IRCA resume en un solo número, de 0 a 100, el grado de riesgo de enfermarse por tomar agua que no cumple las condiciones físicas, químicas o microbiológicas. La escala oficial de interpretación fue definida por el Ministerio de la Protección Social en su Resolución 2115 de 2007 (Ministerio de la Protección Social, 2007): de 0 a 5 sin riesgo; de 5.1 a 14 riesgo bajo; de 14.1 a 35 riesgo medio; de 35.1 a 80 riesgo alto; y de 80.1 a 100 inviable sanitariamente (agua no apta para el consumo).

1.3. Qué contiene la base de datos

La base de datos tiene **19.610 observaciones municipio-año** (cada una corresponde a un municipio en un año específico), que cubren los **32 departamentos de Colombia** más el **Distrito Capital de Bogotá**, y **1.016 municipios**, entre los años **2007 y 2025**. Cada observación indica el valor del IRCA general y sus versiones urbana y rural, junto con el nivel de riesgo y la ubicación geográfica.

1.4. Preparación de los datos

Antes de agrupar, se hicieron tres ajustes: (1) se retiraron 602 registros que representan el promedio de todo un departamento (marcados como "#TODOS") para no mezclarlos con los datos de cada municipio; (2) se convirtieron a número las columnas del IRCA urbano y rural, que estaban en texto; y (3) se estandarizaron las variables para que todas pesen lo mismo al medir distancias. Se trabajó con dos versiones de los datos: la **escenario A** (solo el IRCA) y la **escenario B** (el IRCA junto con el año).

2. Métodos

Se usaron tres métodos de agrupación automática, cada uno con una lógica distinta:

- **K-Means:** reparte los datos en un número fijo de grupos (K) acercando cada observación al "centro" de su grupo. Se usó $K = 3$ (riesgo bajo, medio y alto), con `n_init=10` (diez repeticiones con distinta inicialización), `max_iter=300` (máximo de iteraciones por repetición) y `random_state=42` (semilla fija para que el resultado sea reproducible).
- **DBSCAN:** agrupa las observaciones que están "muy juntas" entre sí y deja fuera, como *ruido*, a las que quedan aisladas (Ester, Kriegel, Sander y Xu, 1996). Se usó `min_samples=5` y, tras calibrar con las curvas de distancia al vecino más cercano, `eps=0.02` para el escenario A y `eps=0.20` para el escenario B.
- **Agrupación jerárquica (Ward):** va uniendo observaciones de abajo hacia arriba, formando un "árbol" (dendrograma). Emplea la **distancia euclidiana** y minimiza la dispersión dentro de cada grupo, según el método propuesto por Ward (1963). A partir del dendrograma se extrajeron dos cortes: **k=2** y **k=3**.

Para decidir cuántos grupos eran adecuados se usaron tres medidas de calidad que no necesitan una respuesta "correcta" previa: el **coeficiente de Silueta** (qué tan compactos y separados

están los grupos), el índice de **Davies-Bouldin** (cuanto menor, mejor) y el de **Calinski-Harabasz** (cuanto mayor, mejor).

3. Resultados

3.1. Qué método agrupa mejor

La Tabla 1 compara los métodos. La agrupación jerárquica con dos grupos sobre el IRCA (escenario A) obtuvo la silueta más alta (0.673), es decir, los grupos más compactos. K-Means quedó muy cerca (0.645). DBSCAN, en cambio, produjo grupos muy desbalanceados, lo que se refleja en valores de Calinski-Harabasz muy bajos.

Tabla 1: Métricas de calidad de cada método por escenario

Método y escenario	Silueta	Davies-Bouldin	Calinski-Harabasz
K-Means (A)	0.645	0.520	70,574.8
K-Means (B)	0.469	0.770	22,825.5
DBSCAN (A)	0.637	0.225	234.5
DBSCAN (B)	0.455	0.373	34.9
Jerárquico (A, k=2)	**0.673**	0.501	52,114.5
Jerárquico (B, k=2)	0.411	0.952	13,259.1
Jerárquico (A, k=3)	0.639	0.521	65,388.7
Jerárquico (B, k=3)	0.377	0.897	16,051.6

3.2. Cómo se separan los municipios

Con K-Means y tres grupos (escenario A), las observaciones municipio-año se dividen de forma natural por su nivel de riesgo:

- **Grupo 1 (bajo):** 11.682 observaciones municipio-año, con IRCA promedio de 5.8 (agua segura).
- **Grupo 2 (medio):** 5.092 observaciones municipio-año, con IRCA promedio de 31.2.
- **Grupo 3 (alto):** 2.836 observaciones municipio-año, con IRCA promedio de 63.2.

La Figura 1 muestra esta separación cuando se añade el año (escenario B): los grupos aparecen además ordenados en el tiempo, con el grupo de riesgo alto concentrado en los años más antiguos.

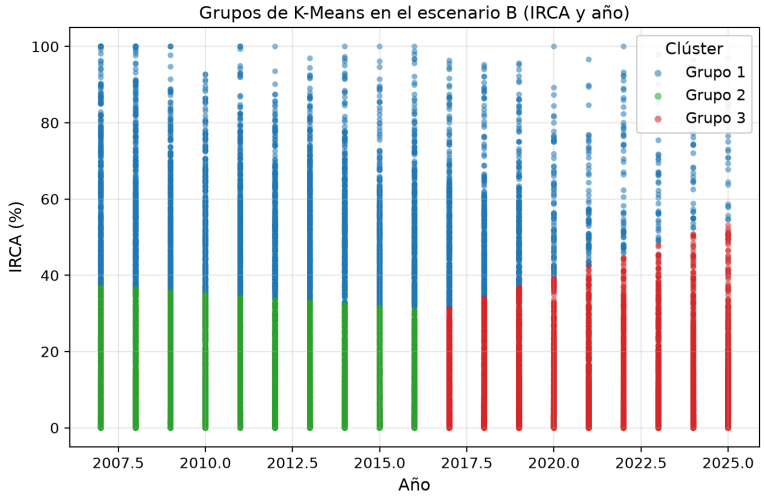


Figura 1: Agrupación de K-Means en el escenario B: cada color es un grupo (riesgo bajo, medio y alto).

3.3. El riesgo baja con los años

En la Figura 2 se observa que el IRCA promedio ha tendido a disminuir entre 2007 y 2025, tanto en general como en las zonas rurales. Esta tendencia es **solo descriptiva**: no demuestra por sí sola una mejora causal de la calidad del agua. El descenso observado puede estar influenciado por cambios en la cobertura del sistema de información o en la composición de los municipios que reportan cada año, de modo que no debe interpretarse como una prueba concluyente de mejoría.

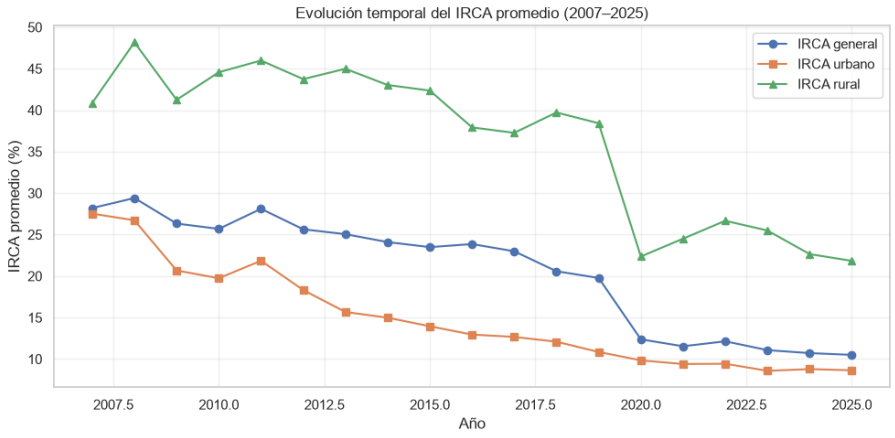


Figura 2: Evolución del IRCA promedio general, urbano y rural (2007–2025).

3.4. El panorama en dos dimensiones

El escenario B contiene únicamente dos variables (IRCA y año), por lo que el análisis de componentes principales (PCA) no reduce realmente la dimensionalidad: se utiliza aquí solo como una transformación que rota los ejes para facilitar la visualización de los grupos. La Figura 3 muestra esta proyección: el primer componente captura el 64.3 % de la variación y el segundo el 35.7 %, lo que confirma que ambas variables aportan información relevante y en direcciones distintas.

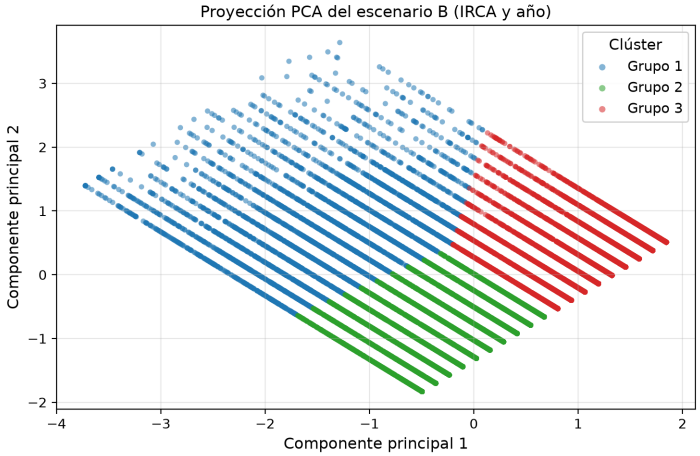


Figura 3: Proyección en dos dimensiones (PCA) del escenario B, coloreada por los grupos de K-Means.

4. Análisis y discusión

4.1. Diferencias entre la ciudad y el campo

Una de las diferencias más notables es entre el agua urbana y la rural. El IRCA rural promedio (37.3) es mucho mayor que el urbano (14.9), lo que indica que los acueductos rurales enfrentan más dificultades. Sin embargo, hay que ser cuidadosos: la mitad de los municipios no reporta el dato rural (51.6 % de valores faltantes), así que esta comparación debe tomarse con prudencia.

4.2. Dónde están los municipios con más riesgo

Los grupos de mayor riesgo concentran departamentos como **Nariño, Bolívar, Huila, Boyacá y Caldas**. Es importante aclarar que esta frecuencia depende de la cantidad de observaciones municipio-año disponibles para cada departamento: un departamento con muchos municipios o con más años de reporte tenderá a aparecer más en cualquier grupo. Por ello, esta

presencia frecuente **no representa necesariamente una mayor tasa de riesgo**; solo indica que en esos departamentos hay muchas observaciones dentro del grupo de riesgo alto.

4.3. Qué aporta DBSCAN

A diferencia de K-Means, DBSCAN no logró separar grupos útiles: casi todas las observaciones quedaron en un solo grupo grande, acompañado de algunos microclústeres muy pequeños y de unos pocos puntos marcados como "ruido". Estos microclústeres y registros de ruido deben interpretarse con cautela: representan observaciones **estadísticamente aisladas** en el espacio de características, pero **no deben considerarse automáticamente anomalías sanitarias**. Son, sencillamente, casos que se separan de la densidad general y que merecen una revisión individual antes de extraer conclusiones.

4.4. Limitaciones del estudio

Las principales limitaciones son: (1) no hay acuerdo perfecto entre las métricas para elegir el número de grupos, por lo que la decisión se apoyó en la silueta y en la sencillez; (2) los datos rurales tienen muchos faltantes; (3) existen dos formas de nombrar los niveles de riesgo y el valor 80.0 queda en la frontera entre dos categorías; y (4) los resultados son descriptivos y no permiten afirmar relaciones causales.

5. Conclusiones

Los datos del IRCA permiten agrupar a los municipios colombianos de forma útil según su nivel de riesgo del agua potable: la agrupación jerárquica con dos grupos ofrece la partición más compacta, mientras que K-Means con tres grupos da una lectura gradual y práctica (bajo, medio y alto). DBSCAN no sirvió para dividir a la población, pero sí para detectar casos extremos que ameritan atención prioritaria. Las diferencias entre lo urbano y lo rural, y la concentración del riesgo en ciertas regiones, son señales útiles para orientar la inversión pública. Para futuros estudios se recomienda completar la información del agua rural, medir la estabilidad de los grupos mediante remuestreo y añadir variables socioeconómicas que expliquen mejor por qué algunos municipios presentan mayor riesgo.

Referencias

Instituto Nacional de Salud. (2025). *Calidad del agua para consumo humano en Colombia* [Conjunto de datos]. Portal Nacional de Datos Abiertos de Colombia, Ministerio de Tecnologías de la Información y las Comunicaciones. `https://www.datos.gov.co/Salud-y-Protecci-n-Social/Calidad-del-Agua-para-Consumo-Humano-en-Colombia/nxt2-39c3`

Ministerio de la Protección Social. (2007). *Resolución 2115 de 2007, por medio de la cual se señalan características, instrumentos básicos y frecuencias del sistema de control y vigilancia para la calidad del agua para consumo humano*. Diario Oficial de Colombia.

Ester, M., Kriegel, H.-P., Sander, J., y Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En E. Simoudis, J. Han y U. Fayyad (Eds.), *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)* (pp. 226–231). AAAI Press.

Ward, J. H., Jr. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244.